Сдача Фазы 2 (КП2) — команда PaperTrace

Отчёт команды PaperTrace по Фазе 2 (КП2).

Репозиторий: https://github.com/Valluk13/PaperTrace (публичный, ветка main).

1. Исходная дорожная карта и её текущий статус

История дорожной карты: пивот после КП1. В октябре (КП1) проект подавался как продукт — «стартап, которого нет ни у кого»: конвейер, который выдаёт пользователю проверенные литературные обзоры. Критика комиссии КП1 была справедливой: нет измерений, нет базы сравнения, есть обещания. После этого дорожная карта тимлида была развёрнута в **измерительный эксперимент**: продуктовый конвейер (теперь режим C) стал объектом измерения, а вокруг него появились честные базы сравнения (A/B), независимый судья, открытый датасет и публикация всех текстов и вердиктов. Продуктовое обещание «уникальный продукт» снято сознательно — это главное отклонение от исходной дорожной карты, и оно выполнено по требованию комиссии КП1. Колонка «планировали» ниже — план уже после пивота.

Планировали (дорожная карта КП1/КП2)	**Статус**	**Где реализовано / доказательство**
Продуктовый конвейер проверенных обзоров (обещание КП1)	**Done как режим C — стал объектом измерения, а не продуктовым заявлением**	`agent_graph.py`, `state.py`; пивот описан выше
Мультиагентный конвейер литобзоров arXiv (5 узлов LangGraph, 2 цикла)	**Done**	`agent_graph.py`, `state.py`; README «Кто за что отвечает»
Бенчмарк трёх режимов A (чат) / B (RAG) / C (PaperTrace) на 35 темах	**Done**	`eval_benchmark.py`, `eval_results_v2.json` — 105 ячеек, все ok
Три метрики проверяемости + независимый судья, читающий страницы PDF	**Done**	`eval_benchmark.py:69` (QUOTE_MIN=25), `verifier_api.py`; метрики в §3
Замер фабрикиации ссылок у чата без поиска	**Done**	7/35 обзоров (20%), CI Уилсона [10%; 36%]; `report.md`
Валидация судьи против внешних разметчиков	**Done (частично)**	4 внешних LLM, 51 утверждение, κ 0.88–1.00 по 49 строкам с вердиктом (`judge_validation.md`); **человек-разметчик не успел → перенесён в план финальной защиты/КП3**
Поиск: полнота выдачи (Recall@K) и её улучшение	**Done замер / отклонение по фиксу**	`recall_test.py`: Recall@6 = 0.08, Recall@25 = 0.24; фикс пересортировки дал лишь 0.04→0.08 — структурный ноль подтверждён, реранкинг ушёл в КП3
Калибровка фильтра надёжности данными	**Done**	`threshold_sweep.py`, 29 статей, 2 разметчика: F1 0.926 @ порог 0.5 (`report.md`)
Сравнение с готовыми продуктами (режим D)	**Done**	`mode_d.py`, `mode_d_details.json`: 4 продукта, 40 ответов, 0/120 мёртвых ссылок

Планировали (дорожная карта КП1/КП2)	Статус	Где реализовано / доказательство
Итоговый отчёт с честными ограничениями	**Done**	`report.md` (43 949 Б; ограничения — 17 пунктов)
Презентация и выступления команды	**Done**	`PaperTrace_КП2_защита.pptx` (14 слайдов), `Выступления_защита_КП2.md`

Итог по карте: из 10 пунктов плана КП2 **8 закрыты полностью**, 2 — с осознанными отклонениями (валидация человеком, фикс recall); продуктовое обещание КП1 учтено отдельной строкой выше — оно стало режимом C. Причины отклонений — в §4.

2. Работающий прототип и реализованные компоненты

Репозиторий: **https://github.com/Valluk13/PaperTrace** (публичный; код и данные прогонов — в коммите `0b8104c`).

Запуск (README):

```
pip install -r requirements.txt        # 9 пинов + requirements.lock.txt
python agent_graph.py "тема"                        # режим C — полный конвейер
python agent_graph.py "тема" --no-filter --no-verifier   # режим B
python eval_benchmark.py --dataset eval_dataset.json --limit 3
python -m unittest discover tests                   # 42 офлайн-теста, 0 запросов
```

Компоненты: `security_guard → planner → arxiv_search → reliability_rag → writer_verifier` (циклы: поиск ≤2 итераций, Self-Correction ≤2 проходов); измерительный харнесс `eval_benchmark.py` + `eval_draft.py` (абляция) + `mode_d.py` (внешние продукты) + `judge_validation.py`; сервисные `preflight.py` (предполётная проверка), `repair_cells.py`/`zero_cells.py` (ремонт прогона без повторной оплаты).

Конкуренты и отличие (уточнение по запросу комиссии)

Измеренные в режиме D (нашим кодом, без вызова нашего LLM): Gemini Argon 4 Low, Gemini Flash 3.8 High, Kimi K3.1 Pro, GPT 6.1 Sol Pro (многошаговый агент) — 40 ответов на 10 тем: 0 мёртвых ссылок из 120, однако номера страниц навязаны форматом нашего промта и содержательно их не проверял никто: ни мы (это план КП3), ни, насколько нам известно, сами продукты.

Продуктовые конкуренты (позиционирование, не измерены): NotebookLM даёт постраничные цитаты только по PDF, загруженным самим пользователем; Perplexity, Elicit и Deep Research дают кликабельные источники без номеров страниц и без машинной сверки дословности; ни один не публикует метрику типа «верная страница» и не позволяет выключать свои узлы для абляции.

Научные аналоги: OpenScholar (самокритика и абляции, но без постраничных цитат и машинной сверки дословности); PaperQA2 (постраничные цитаты и замер цены, но закрытый контур: без независимого судьи и проверки круговости); RARR и Chain-of-Verification (семейство «исследуй и перепиши», к которому относится наш верификатор; мы добавляем точную страницу PDF и программную сверку цитаты кодом); ALCE (стандартизированные метрики цитирования; мы добавляем адресную метрику «верная страница» и замер фабрикиации на скачанных PDF); CiteCheck

и аудит Topaz et al. (детекция и масштаб фабрикиации); AIS (теоретическое различение атрибуции и истинности; мы даём его эмпирическую демонстрацию).

Отличие одной строкой: точная страница PDF на каждый тезис + независимый судья с валидацией + проверка круговости на полном охвате + атрибуция эффекта по шагам + цена одного проверенного тезиса (`report.md`, «Связанные работы» и «Для кого и против кого»).

3. Первые проверяемые результаты и тесты, на которых они получены

Прогон v2 (08.11): 35 тем × 3 режима = **105 ячеек, все `ok`**. Судья — llama-3.3-70b, читает страницы PDF; писатель — qwen-2.5-72b.

Метрика	A — чат	B — RAG	C — PaperTrace	Δ C−B и значимость
Существование ссылки	93%	100%	100%	у C 100% по построению, из сравнения исключено
Поддержка текстом	1%	91%	97%	**+5,7 п.п.**, CI [+2,2; +9,3], p перм. 0.004, Холм 0.007
Верная страница	0%	79%	91%	**+12,0 п.п.**, CI [+6,7; +18,2], p перм. 0.000, Холм 0.000

Тесты и замеры, на которых получены цифры:

1. **42 офлайн-теста** (`tests/`, `Ran 42 tests … OK`) — инварианты контракта, единый порог 25 знаков, статусы ячеек, знаменатели метрик.

2. **Перестановочный тест** 200 000 переворотов, seed 7 + bootstrap 20 000 (`make_report.py`) — значимость Δ C−B.

3. **Перепроверка правила судьи** (`eval_results_semantic_v2.json`, 70 ячеек, охват 35/35): без требования дословной цитаты Δ → 0,0 / +1,2 п.п. — проверка круговости метрики.

4. **Аблация черновика** (`eval_results_draft_v2.json`, 35 тем): значимый шаг один — верификатор (страница +5,8 п.п., p=0.001).

5. **Валидация судьи** (`judge_sample.csv`, 51 утверждение × 4 внешних LLM): к 0.88–1.00 по 49 строкам с вердиктом; accuracy судьи 0.69 (строгое) / 0.90 (семантическое); FP 4 / FN 11 — судья строже разметчиков на тезисах C: абсолютные цифры C скорее занижены.

6. **Recall-тест** (`recall_test.py`, 12 тем, 25 эталонных id, без LLM): Recall@6 0.08, Recall@25 0.24.

7. **Аудит режима D** (`mode_d_details.json`): 0/120 мёртвых ссылок у 4 продуктов.

8. **Расходы по факту** (`polza_usage_export_2026-11-08.csv`): 5 797 запросов, 531,93 ₽ за проект; 3,23 ₽/обзор C против 8,96 ₽ за один ответ GPT-агента.

Воспроизводимость: вердикты судьи закэшированы (`eval_cache.json`) — метрики пересчитываются из файлов без новой оплаты; `python make_report.py --results eval_results_v2.json` восстанавливает отчёт. Оговорка (пишем сами): прогон v2 шёл с незакоммиченными правками — `eval_run_meta.json` несёт `git_sha` + список `git_dirty`.

4. Изменения в плане, причины отклонений, риски, задачи до финальной защиты

Отклонения и причины:

- **Пивот «продукт → измерительный эксперимент» после КП1** — главное изменение плана; причина: критика комиссии «нет измерений, нет базы сравнения». Продуктовые обещания сняты, конвейер стал режимом С и объектом измерения.
- **Фикс поиска не помог.** Планировали поднять Recall пересортировкой кандидатов; замер показал 0.04→0.08 — 92% эталонов не доходят до топ-6 ни из одного канала. Причина гипотезная (формулировки запросов vs слабость канала), разделение — факторный эксперимент КП3. Отклонение задокументировано, не замолчано.
- **Формулировка главного вывода ужесточена по ходу работы.** После перепроверки без дословной цитаты эффект исчезает (Δ→0) — поэтому заявляем «проверяемость, а не правдивость». Это изменение плана подачи, вызванное собственным замером круговости.
- **Валидация судьи человеком перенесена** в план финальной защиты/КП3: четыре внешних LLM дали к 0.88–1.00, но согласие LLM ≠ истинность.
- **Вклад фильтра надёжности не разделён** от планировщика: при n=35 MDE80 ≈ 5,2/8,5 п.п., шаги аблации мельче порога различимости.

Риски: судья — LLM без человека, n=35, один писатель и один судья — в `report.md`, «Ограничения» (17 пунктов); сверх того измерены и названы здесь: утечка ChromaDB ~6 МБ/вызов (README), нет чекпоинтов LangGraph и очереди ячеек (1000 тем ≈ 3 суток и ~3000 ₽ — оценка из медиан, не замер), граничная вилка эффекта по поддержке [−1,1; +8,7] п.п. при предельной атрибуции спорных вердиктов (`analysis/boundary.py`, коммит — задача §4).

Следующие шаги (финальная защита и КП3): слепая человеческая разметка 100–150 утверждений B/C — внешний критерий вне цикла Self-Correction; факторный эксперимент «канал × формулировка» и реранкер с целевыми метриками Recall@25 ≥ 0.5 и Recall@6 ≥ 0.3; аблация фильтра надёжности на большей выборке; фактчекер чужих обзоров — содержательная проверка страниц режима D.

5. Конкретный вклад каждого участника и самооценка

Участник	Роль	Вклад (подтверждено git)
Валентин (Valluk13)	тимлид	32 коммита: граф и контракт (`agent_graph.py`, `state.py`, `common.py`), ядро-фиксы `4118cfc`, интеграционная сборка `0b8104c`, мержи всех PR, инвариант-тесты, отчёт/презентация/координация
Kate414-1	Eval & QA	5 коммитов, PR #2 и #16 (`a682e53`): `eval_benchmark.py` (статусы ячеек, resume, QUOTE_MIN=25), пересудки, режим D, `judge_validation.py`, `make_report.py`, отчёт

Участник	Роль	Вклад (подтверждено git)
lijekwo	Data Engineer	5 коммитов, PR #3/#6/#17 (`3dbfda9`): `arxiv_searcher.py` — каналы arXiv/OpenAlex, надёжность сбоев, `recall_test.py`
Gleb (itishnik-dev)	RAG & Vector DB	3 коммита, PR #1 и #8 (`820ad16`, `5b67f73`, `5e55739`): `reliability_rag.py` — фильтр надёжности, ChromaDB-ретривер, калибровка порога (29 статей, 2 разметчика), `dump_papers.py`, `threshold_sweep.py`
artikClown	Backend & Security	3 коммита, PR #4/#18 (`32dc771`): `verifier_api.py` — guard LLM-first, единый порог дословности, перенос тезисов; `guard_tests.py/md`

Вклад команды в истории честный: функциональные зоны пришли PR'ами от имён владельцев (#1–#3 04.11, #4 31.10, #6–#8 05.11, #16–#18 08.11; #5 закрыт без мержа), интеграцию и ядро вёл тимлид.

Самооценка: 4 из 5. Все заявленные метрики получены, проверены и воспроизводимы из файлов; слабые места найдены и опубликованы нами самими (круглость, структурный ноль recall, MDE). Балл снят сами с себя за два перенесённых пункта (человек-разметчик, разделение вклада фильтра) и за прогон, шедший поверх незакоммиченных правок.

6. Дополнительные элементы сверх базовой дорожной карты

Сделано поверх базовой дорожной карты (список фактический):

- **Валидация судьи четырьмя внешними LLM разных производителей** (Gemini Argon, Claude Opus 5.5, GPT 6.1 Sol Pro, Kimi K3.1 Pro) с каппой и разбором FP/FN.
- **Проверка круговости метрики на полном охвате** (70 ячеек пересудки + аблация черновиков) и граничная вилка эффекта [−1,1; +8,7] п.п. из кэша вердиктов.
- **Репликация v1↔v2** на двух сборках: агрегаты B совпали до сотых (1.00/0.91/0.79).
- **Режим D** — аудит четырёх готовых продуктов нашим кодом без вызова нашего LLM.
- **Учёт стоимости по факту** из выгрузки провайдера (531,93 ₽; «измерение дороже генерации»: судья 203,40 ₽ против писателя 87,54 ₽).
- **Obsidian-vault документации** (108 заметок + canvas-схема: узлы, концепты, термины в Фейнман-формате, история решений) для онбординга команды.
- **42 инвариант-теста**, запрещающие регресс контракта и метрик.